# BIG DATA







#### Coordenação:

Prof. Dr. Adolpho Walter Pimazzi Canton

Profa. Dra. Alessandra de Ávila Montini Disciplina: Aplicações de Big Data com Hadoop

Tema da Aula: YARN

Profa. Rosangela de Fátima Pereira

Junho de 2016

### Currículo

#### Formação

- Mestrado em Engenharia de Computação pela Escola Politécnica da Universidade de São Paulo (Poli-USP) (em andamento)
- Especialização em Tecnologia Java pela Universidade Tecnológica Federal do Paraná (UTFPR) (2011)
- Tecnologia em Análise e Desenvolvimento de Sistemas pela UTFPR (2011)
- Bacharelado em Administração de Empresas pela Universidade Estadual do Norte do Paraná (UENP) (2007)

#### Experiência

- Professora de Big Data Analytics em empresas e programas de MBA FIA (2013 atual)
- Pesquisadora no Laboratório de Arquitetura e Redes de Computadores (LARC) USP (2013 atual)
- Professora de cursos de engenharia na UTFPR (2011 -2012)
- Analista de sistemas na BSI Tecnologia (2009-2010)

LinkedIn: <a href="https://br.linkedin.com/pub/rosangela-de-fatima-pereira/68/a10/b56">https://br.linkedin.com/pub/rosangela-de-fatima-pereira/68/a10/b56</a>

Apaixonada por Big Data!





### Objetivo da Aula

Apresentar ao aluno características do Ecossistema Hadoop e fundamentos do YARN



### Conteúdo da Aula

- Revisão da aula anterior
- Ecossistema Hadoop
- YARN
- Considerações finais



#### Aula anterior

Conjunto de classes que podem ser herdadas para utilização de funcionalidades pré-definidas

O conjunto de classe é dividido nos seguintes componentes:

- Hadoop Common
- Hadoop Distributed File System (HDFS)
- Hadoop MapReduce
- Hadoop YARN



#### Aula anterior

#### Os seguintes passos serão executados:

- 1. Implementar as classes da aplicação
- 2. Gerar um arquivo JAR da aplicação
- 3. Executar o JAR no ambiente Hadoop
- 4. Visualizar o resultado da aplicação



#### Aula anterior

Serão implementadas 3 classes:

ContaPalavrasMap.java

ContaPalavrasReduce.java

ContaPalavrasDriver.java

 Para facilitar o desenvolvimento das classes foi criado um projeto inicial chamado ContaPalavras contendo a estrutura-base das classes.



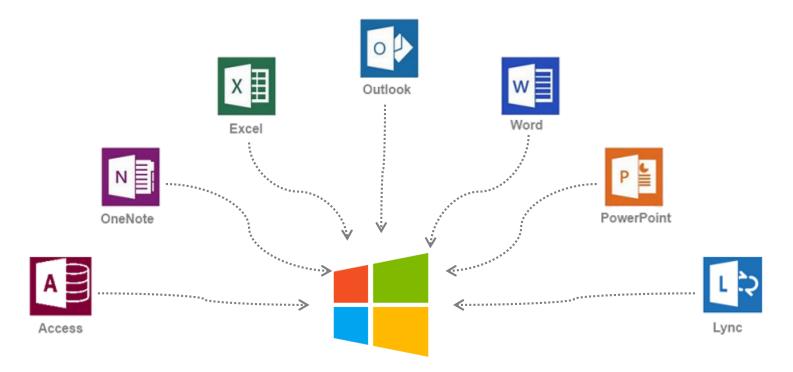
#### Conteúdo da Aula

- Revisão da aula anterior
- Ecossistema Hadoop
- YARN
- Considerações finais

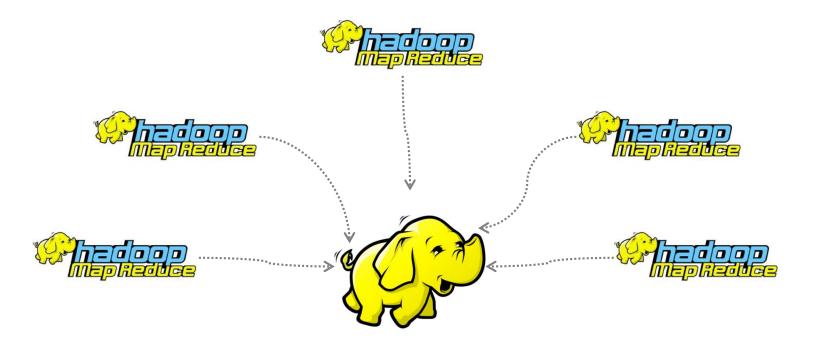


<u>Hadoop</u>

"Um sistema operacional para Big Data"





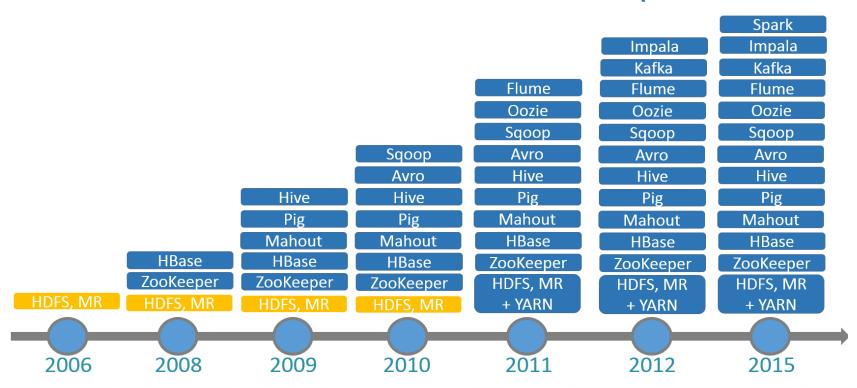




Com a adoção do Hadoop, as empresas foram percebendo a necessidade de novas tecnologias e novas técnicas para facilitar e aperfeiçoar o armazenamento e processamento dos dados

Com isso, Hadoop foi evoluindo com o passar dos anos...





Preciso gerenciar os processos executados no Hadoop por inúmeros usuários e serviços...



#### ZooKeeper

- Serviço para coordenação de processos de aplicações distribuídas
- Oferece alta disponibilidade às aplicações
- Desenvolvido no Yahoo!
- Não é de uso exclusivo do Hadoop





Preciso armazenar meus dados em um banco de dados NoSQL...



#### **HBase**

- Banco de dados NoSQL do Hadoop
- Versão open-source do Google Big Table
- Acelera o processo de escrita dos dados
- Orientado a colunas





Preciso de uma linguagem em script para processar meus dados...



#### Pig

- Linguagem em formato de script para manipulação de dados -PigLatin
- Converte o código em MapReduce jobs
- Oferece operações padrões de processamento de dados, filter, join, group-by, order-by
- Linguagem de fácil compreensão e manutenção
- Desenvolvido originalmente no Yahoo!





Preciso de uma linguagem similar à SQL...



#### Hive

- Linguagem de abstração de alto nível
- Utiliza HiveQL, uma linguagem similar à SQL
- Gerar MapReduce Jobs
- Desenvolvido pelo Facebook





Preciso mover os dados para o HDFS no momento que eles são gerados...



#### Flume

- Serviço distribuído, confiável e de alta disponibilidade
- Transfere grande volume de dados no momento que eles são gerados
- Utilizado para inserção de arquivos (logs da web, logs da rede, etc.)





Preciso processar dados em formato de tabelas...



#### Sqoop

- Sqoop significa "SQL para Hadoop"
- Importa tabelas do banco de dados relacionais para HDFS e viceversa
- Utiliza MapReduce para importar os dados
- Suporta banco de dados Oracle





Preciso processar rapidamente as mensagens coletadas das fontes de dados...



#### Kafka

- Serviço de distribuição de mensagens
- Oferece alta vazão de dados, replicação, particionamento de tarefas e tolerância a falhas
- Muito utilizado para coleta de logs e processamento de streaming





Preciso executar técnicas de aprendizado de máquina em modo distribuído...



#### **Mahout**

- Linguagem que facilita a execução de algoritmos de aprendizado de máquina
- Fornece suporte às seguintes técnicas:
  - Filtragem colaborativa: sistemas de recomendações
  - Agrupamento (clustering): permite identificar grupos de acordo com características similares
  - Classificação: técnicas para categorizar itens não-classificados a uma determinada categoria
  - Frequent Itemset Mining: analisa itens em um grupo e identifica quais deles normalmente aparecem juntos





Preciso processar outras aplicações além do modelo de processamento MapReduce...



#### Hadoop 1.x

- Falta de suporte para outros paradigmas e modelos de programação em Big Data
  - Processamento em lote, streaming, in-memory, em grafos,...
- Problemas de escalabilidade em cluster com mais de 4.000 nós
- Falta de flexibilidade na configuração de slots dos nós escravos



### Conteúdo da Aula

- Revisão da aula anterior
- Ecossistema Hadoop
- YARN
- Considerações finais



#### YARN

#### Principais diferenças entre Hadoop 1.x e Hadoop 2.x (YARN):

- Divisão das duas funcionalidades do JobTracker:
  - Gerenciamento de recursos
  - Gerenciamento/monitoramento de jobs



#### **YARN**

#### Principais diferenças entre Hadoop 1.x e Hadoop 2.x (YARN):

- Divisão das duas funcionalidades do JobTracker:
  - Gerenciamento de recursos
  - Gerenciamento/monitoramento de jobs
- MapReduce se torna uma das aplicações do Hadoop

O



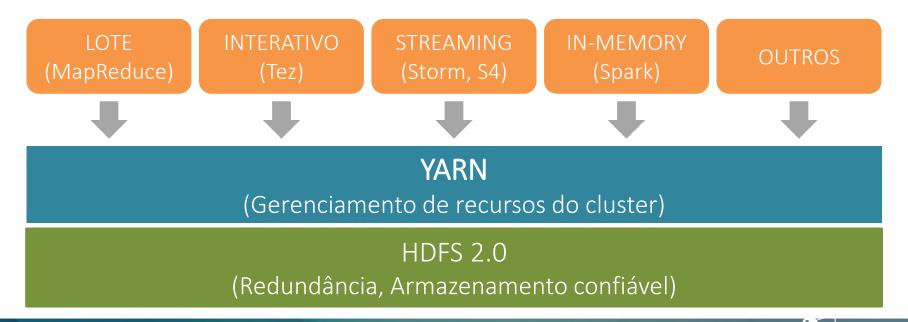
#### YARN

#### Principais diferenças entre Hadoop 1.x e Hadoop 2.x (YARN):

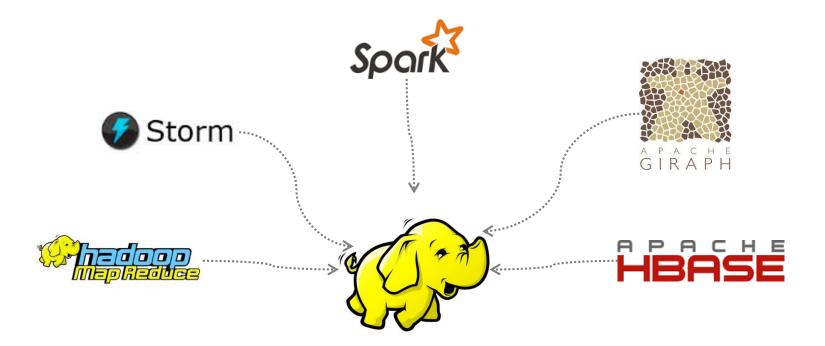
- Divisão das duas funcionalidades do JobTracker:
  - Gerenciamento de recursos
  - Gerenciamento/monitoramento de jobs
- MapReduce se torna uma das aplicações do Hadoop
- Remoção de slots fixos: recursos dos nós são alocados para as aplicações somente quando for requisitado



#### **YARN** – Yet Another Resource Negotiator







#### YARN = Yet Another Resource Negotiator

#### Apache Hadoop YARN: Yet Another Resource Negotiator

```
Vinod Kumar Vavilapalli<sup>h</sup>
                                         Arun C Murthy<sup>h</sup>
                                                                       Chris Douglas<sup>m</sup>
                                                                                                   Sharad Agarwali
Mahadev Konar<sup>h</sup>
                                                                                                         Hitesh Shah<sup>h</sup>
                            Robert Evans<sup>y</sup>
                                                     Thomas Graves<sup>y</sup>
                                                                                  Jason Lowey
                                                                           Owen O'Malleyh
Siddharth Seth<sup>h</sup>
                          Bikas Saha<sup>h</sup>
                                                 Carlo Curino<sup>m</sup>
                                                                                                        Sanjay Radia<sup>h</sup>
                              Benjamin Reed<sup>f</sup>
                                                                Eric Baldeschwieler<sup>h</sup>
     h: hortonworks.com, ": microsoft.com, 1: inmobi.com, y: yahoo-inc.com, f: facebook.com
```

#### Abstract

The initial design of Apache Hadoop [1] was tightly focused on running massive, MapReduce jobs to process a programming frameworks onto YARN viz. Dryad, Giraph, Hoya, Hadoop MapReduce, REEF, Spark, Storm, Tez.

http://br.hortonworks.com/blog/apache-hadoop-yarn-wins-best-paper-award-at-socc-2013/



#### YARN é responsável por:

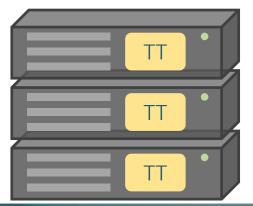
- Gerenciamento de recursos do cluster
  - Alocação de recursos
  - Controles de segurança
  - Monitoramento de cargas de trabalho
  - Operações de administradores
- Escalonamento de tarefas



#### Anteriormente

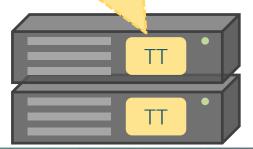
#### JobTracker (JT)

- Gerenciador de recursos
- Escalonador de jobs



#### TaskTracker (TT)

Executam as tarefas
 MapReduce



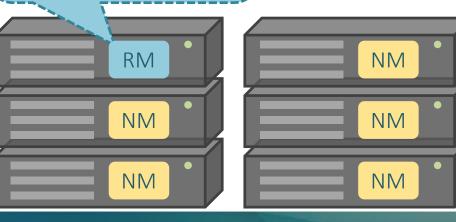




#### Atualmente

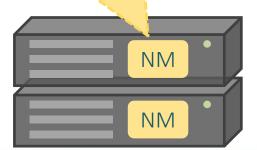
#### ResourceManager(RM)

- Gerenciador de recursos
- Escalonador global de recursos



#### NodeManager(NM)

Monitor de uso de recursos







#### Atualmente

# NodeManager(NM) • Monitor de uso de recursos NM Container AM

#### Container

• Fração dos recursos do NM

#### ApplicationMaster (AM)

• Execução e monitoramento de tarefas





Aplicação: um job submetido ao Hadoop (ex. MapReduce job)

Aplicação: um job submetido ao Hadoop (ex. MapReduce job)

Container: unidade de alocação de recursos (ex.: c1 = 1 GB, 2 CPU)

substitui os slots fixados das tarefas map e reduce



Aplicação: um job submetido ao Hadoop (ex. MapReduce job)

Container: unidade de alocação de recursos (ex.: c1 = 1 GB, 2 CPU)

substitui os slots fixados das tarefas map e reduce

Resource Manager: escalonador global de recursos



Aplicação: um job submetido ao Hadoop (ex. MapReduce job)

Container: unidade de alocação de recursos (ex.: c1 = 1 GB, 2 CPU) substitui os slots fixados das tarefas map e reduce

Resource Manager: escalonador global de recursos

Node Manager: gerencia o ciclo de vida do container, monitora os recursos do container (1 por máquina)

Aplicação: um job submetido ao Hadoop (ex. MapReduce job)

Container: unidade de alocação de recursos (ex.: c1 = 1 GB, 2 CPU) substitui os slots fixados das tarefas map e reduce

Resource Manager: escalonador global de recursos

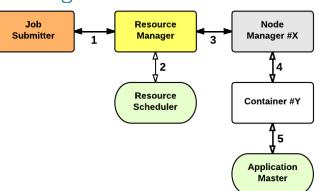
Node Manager: gerencia o ciclo de vida do container, monitora os recursos do container (1 por máquina)

Application Master: gerencia a execução e escalonamento das tarefas (1 por aplicação)



#### Fluxo de execução de uma aplicação no YARN

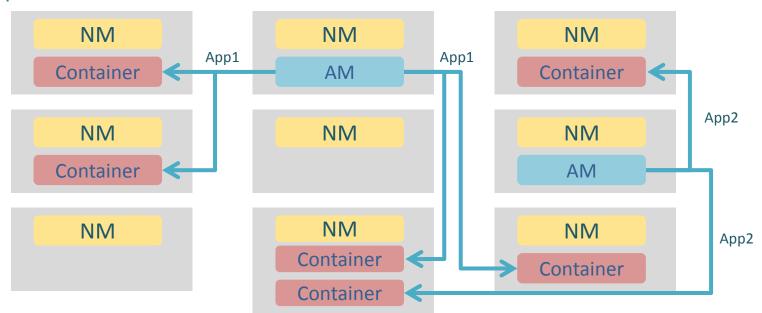
- 1. Um cliente submete uma aplicação (job) para o Resource Manager
- 2. O Resource Manager aloca um Container
- 3. O Resource Manager faz contato com o Node Manager
- 4. O Node Manager inicia o Container
- 5. O Container executa a Application Master



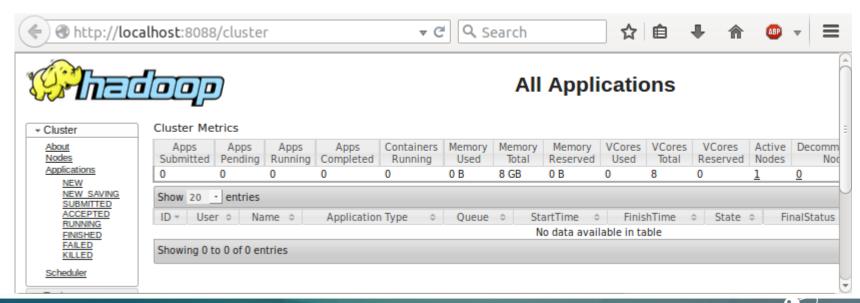


#### RM

#### Exemplo de um cluster YARN

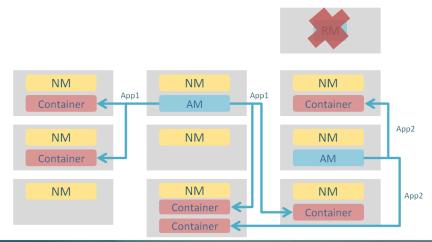


Interface Web do Resource Manager (http://rmhost:8088)





- Resource Manager é um ponto único de falha do YARN
  - Se esse vier a falhar, todo o cluster fica indisponível até que ele seja novamente iniciado





- Solução: Resource Manager High Availability (RM HA)
  - Permite executar RMs redundantes
  - Arquitetura Active/StandBy
  - Oferece uma recuperação de falhas rápida e automática
  - Utiliza ZooKeeper para determinar qual RM deve permanecer ativo

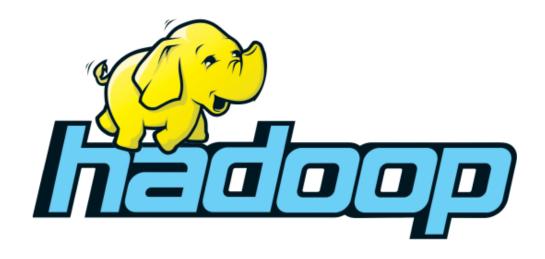


# Ecossistema Hadoop

Preciso de uma plataforma para atuar com Big Data...

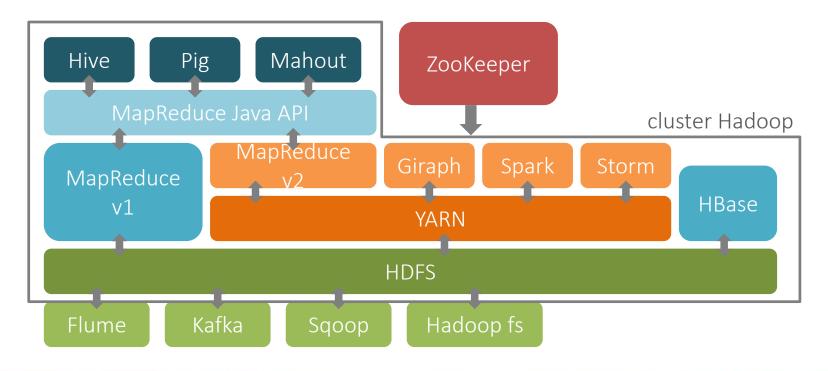


# Ecossistema Hadoop





# Ecossistema Hadoop

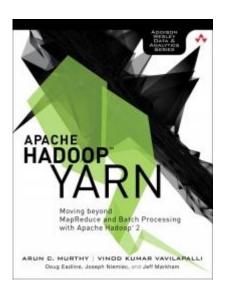


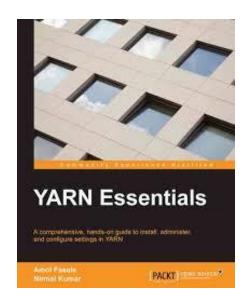
## Conteúdo da Aula

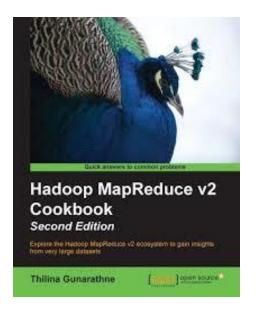
- Revisão da aula anterior
- Ecossistema Hadoop
- YARN
- Considerações finais



## Livros sobre YARN





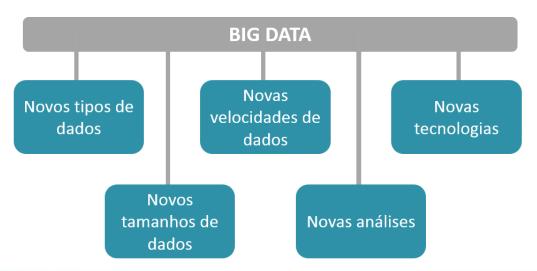




# Considerações finais

Lembre-se...

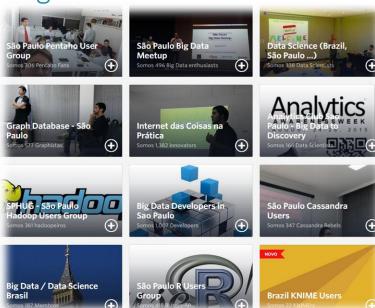
#### Big Data requer inovação!

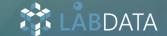


# Considerações finais

Recomendações de grupos de Big Data

www.meetup.com



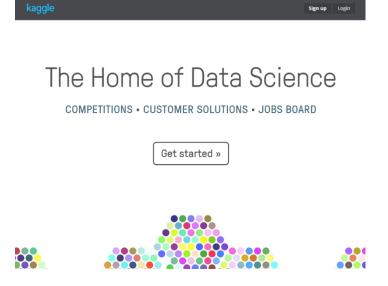




# Considerações finais

Recomendações de sites de Big Data

https://www.kaggle.com/







# Referências Bibliográficas

WHITE, Tom. Hadoop: The definitive guide. "O'Reilly Media, Inc.", 2012.

VAVILAPALLI, Vinod Kumar et al. Apache hadoop yarn: Yet another resource negotiator.

In: Proceedings of the 4th annual Symposium on Cloud Computing. ACM, 2013. p. 5.

VAVILAPALLI, Vinod Kumar et al. Apache hadoop yarn: Yet another resource negotiator.

In: Proceedings of the 4th annual Symposium on Cloud Computing. ACM, 2013. p. 5.

KAMBURUGAMUVE, Supun et al. Survey of Apache Big Data Stack. 2013. Tese de

Doutorado. Ph. D. Qualifying Exam, Dept. Inf. Comput., Indiana Univ., Bloomington, IN.



# Referências Bibliográficas

GOLDMAN, Alfredo et al. **Apache Hadoop: conceitos teóricos e práticos, evolução e novas possibilidades**. XXXI Jornadas de atualizações em informática, p. 88-136, 2012.

MONTEITH, J. Yates; MCGREGOR, John D.; INGRAM, John E. Hadoop and its Evolving Ecosystem. In: IWSECO@ ICSOB. 2013. p. 57-68.

FASALE, Amol; KUMAR, Nirmal. Yarn Essentials. Packt Publishing Ltd, 2015.

